# INFORME DE INTERPRETACIÓN BIOLÓGICA

Análisis diferencial de expresión con PyDESeq2 y enriquecimiento funcional con GSEApy de tumor frente a tejido normal con los datos TCGA-BRCA

Ángela del Rocío De La Rosa Ruiz

---

El objetivo del presente informe consiste en llevar a cabo la interpretación biológica de los resultados obtenidos en el análisis de expresión diferencial y enriquecimiento funcional llevado a cabo entre muestras de tejido tumoral mamario y muestras de tejido normal con los datos TCGA-BRCA.

Criterios estadísticos

Se evaluaron dos parámetros estadísticos para determinar los genes expresados de forma diferencial en el tejido tumoral mamario respecto al tejido normal:

- log2 FoldChange (log2 FC): indica la magnitud del cambio en los niveles de expresión. Un valor de log2 FoldChange positivo denota una mayor expresión génica en el tejido tumoral, mientras que un valor de log2 FoldChange negativo supone una menor expresión génica en el tejido tumoral. El umbral de log2 FoldChange en este análisis se fijó en $|\log2\ FC| > 1$, lo que implica que el cambio de expresión de un gen determinado en el tejido tumoral se considera sustancial cuando se duplica o se reduce a la mitad respecto al nivel de expresión de dicho gen en el tejido normal. Así, los genes con un $\log2\ FC > 1$ se encuentran sobreexpresados, mientras que los genes con un $\log2\ FC < -1$ se consideran reprimidos.
- p-valor ajustado (padj): mide la significación estadística de los cambios observados teniendo en cuenta el análisis simultáneo de miles de genes. Para modelizar adecuadamente los recuentos de expresión y su variabilidad, los datos se ajustaron mediante una distribución binomial negativa. Ya que se realizan múltiples contrastes, los p-valores se corrigieron mediante el método de Benjamini-Hochberg para controlar la tasa de falsos descubrimientos (FDR). En este análisis, se fijó el umbral del p-valor ajustado en $padj < 0.05$, considerando como significativos los genes cuyo p-valor ajustado cumpla dicho requisito.

Se consideran genes expresados de forma diferencial aquellos donde $|\log2\ FC| > 1$ y $padj < 0.05$.

Para llevar a cabo el enriquecimiento funcional (GO y Reactome), se realizó un análisis de sobre-representación para identificar las rutas biológicas alteradas en el tejido tumoral mamario, utilizando el test exacto de Fisher con el universo de fondo completo (res_df). Los p-valores obtenidos se ajustaron mediante el método de Benjamini-Hochberg.

Visión global y genes destacados

La distribución global de los cambios de expresión génica se visualiza mediante el MA Plot (Figura 1) y el Volcano Plot (Figura 2). Mientras que el MA Plot muestra la relación entre la expresión media de los genes y su cambio de expresión (log2 FC) en el tejido tumoral respecto al tejido normal, el Volcano Plot integra la magnitud del cambio (log2 FC) con la significancia estadística (-log10(padj)), permitiendo identificar las poblaciones de genes sobreexpresados (Up) y reprimidos (Down) en el tejido tumoral respecto al tejido normal..

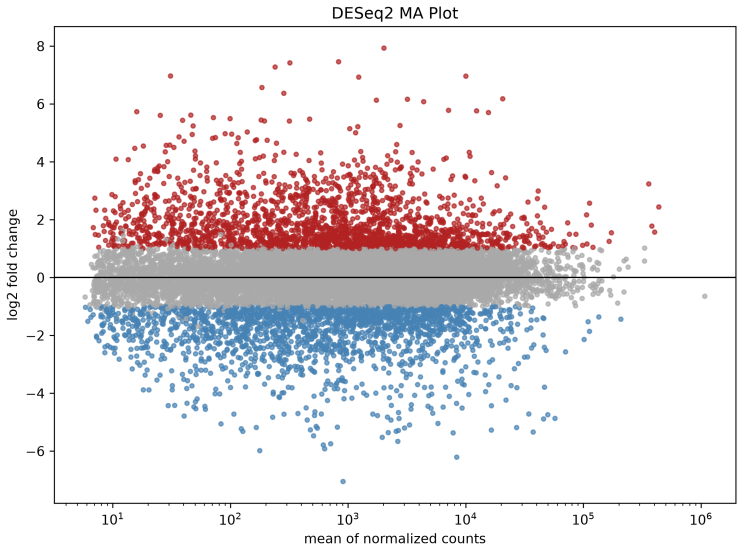



Figura 1: MA Plot del contraste tumor frente a normal tras normalización de DESeq2. Cada punto se corresponde con un gen. El eje X indica abundancia media y el eje Y el cambio de expresión (log2 FoldChange). La dispersión respecto a log2 FC = 0 permite identificar genes con cambios biológicamente relevantes.

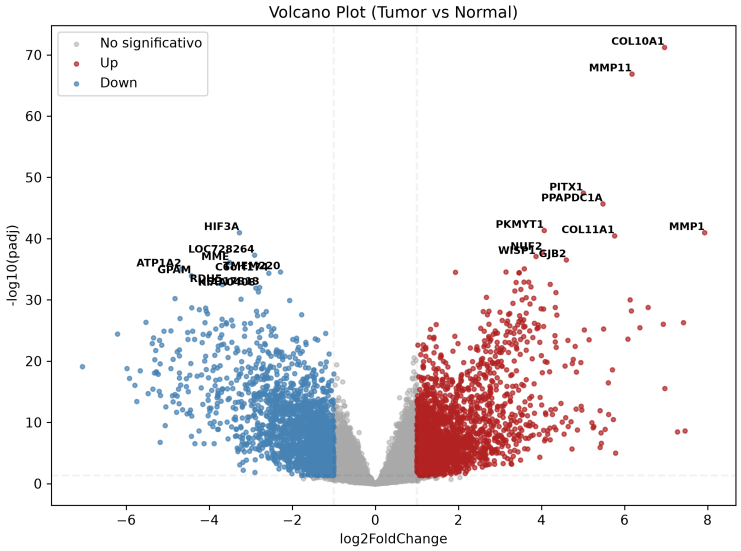



Figura 2: Volcano Plot del contraste tumor frente a normal. Cada punto se corresponde con un gen. El eje X muestra la magnitud del cambio (log2 FoldChange) y el eje Y la evidencia estadística (-log10(padj)). Las líneas discontinuas marcan los umbrales usados en el proyecto (padj < 0.05 y |log2 FC| > 1), lo que permite separar genes sobreexpresados (Up), reprimidos (Down) y no significativos.

A partir del conjunto de genes diferencialmente expresados, se procede a examinar aquellos que experimentan una mayor alteración transcripcional. A continuación, se estudian los 10 genes con mayor sobreexpresión (Up) y los 10 genes más reprimidos (Down) en el tejido tumoral, analizando su importancia biológica para explicar las diferencias moleculares clave entre el tejido tumoral y el tejido normal.

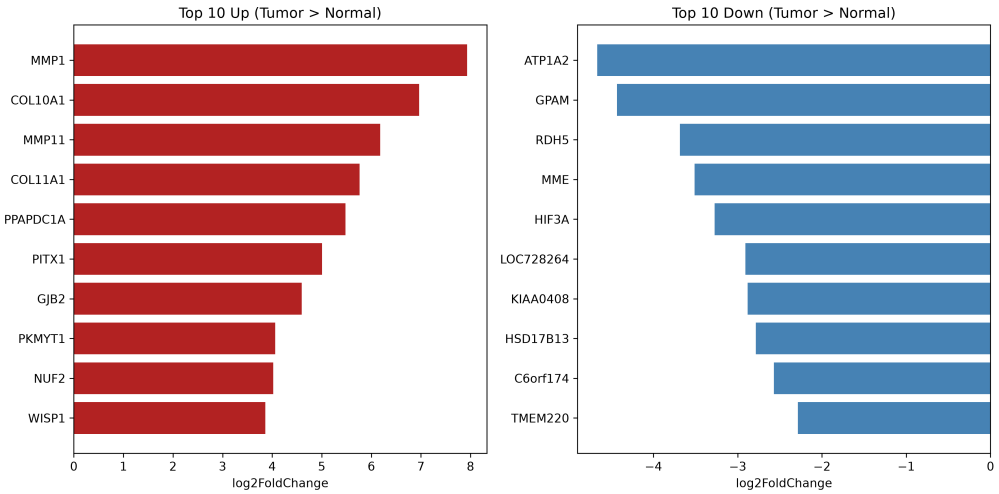



Figura 3: Top 10 de genes con mayor cambio en el contraste tumor frente a normal. El panel izquierdo muestra genes sobreexpresados en tumor (Up) y el panel derecho muestra genes reprimidos en tumor (Down). El eje horizontal indica log2 FoldChange, donde valores positivos indican una mayor expresión en tumor y valores negativos mayor expresión en el tejido normal.

| Gen | log2 FC | padj |
|---|---|---|
| COL10A1 | 6.96 | 5.95e-72 |
| MMP11 | 6.18 | 1.27e-67 |
| PITX1 | 5.00 | 3.58e-48 |
| PPAPDC1A | 5.48 | 2.09e-46 |
| PKMYT1 | 4.06 | 4.52e-42 |
| MMP1 | 7.93 | 1.03e-41 |
| COL11A1 | 5.76 | 3.35e-41 |
| NUF2 | 4.02 | 1.76e-38 |
| WISP1 | 3.86 | 8.27e-38 |
| GJB2 | 4.60 | 2.78e-37 |

Tabla 1: Genes con mayor sobreexpresión en tumor.

| Gen | log2 FC | padj |
|---|---|---|
| HIF3A | -3.27 | 1.03e-41 |
| LOC728264 | -2.91 | 5.09e-38 |
| MME | -3.51 | 8.03e-37 |
| ATP1A2 | -4.67 | 9.13e-36 |
| TMEM220 | -2.29 | 2.66e-35 |
| C6orf174 | -2.57 | 4.24e-35 |
| GPAM | -4.43 | 1.17e-34 |
| RDH5 | -3.69 | 3.22e-33 |
| HSD17B13 | -2.79 | 8.90e-33 |
| KIAA0408 | -2.88 | 1.23e-32 |

Tabla 2: Genes con menor expresión relativa en tumor.

Respecto a los genes sobreexpresados (Up) mostrados en el Top 10, cabe destacar MMP11, cuya elevada expresión favorece la proliferación, invasión estromal y progresión tumoral (Kim et al., 2021; Zhuang et al., 2021), junto con otros marcadores de matriz extracelular como COL11A1 (Cancer Genome Atlas Network, 2012). Por otra parte, en cuanto a los genes reprimidos (Down) mostrados en el Top 10, la disminución de marcadores metabólicos y lipídicos como HSD17B13 y GPAM evidencia la pérdida de las funciones especializadas, el metabolismo lipídico y la diferenciación tisular propios del tejido mamario sano (Vargas et al., 2012).

Enriquecimiento funcional (GO y Reactome)

Para continuar con el estudio de los mecanismos moleculares subyacentes, se realizó un análisis de enriquecimiento funcional empleando las librerías GO_Biological_Process_2023 y Reactome_2022. La evaluación separada de las firmas up y down permite caracterizar las alteraciones funcionales clave entre el tejido tumoral mamario y el tejido normal.

1. Enriquecimiento GO (Biological Process) en genes Up:

El análisis de procesos biológicos en los genes sobreexpresados en el tumor mamario muestra una predominancia de términos relacionados con la organización de microtúbulos, puntos de control de la mitosis y la segregación de cromátidas hermanas. Este perfil confirma la alta tasa proliferativa e inestabilidad cromosómica característica de la firma tumoral del cáncer de mama (Cancer Genome Atlas Network, 2012).

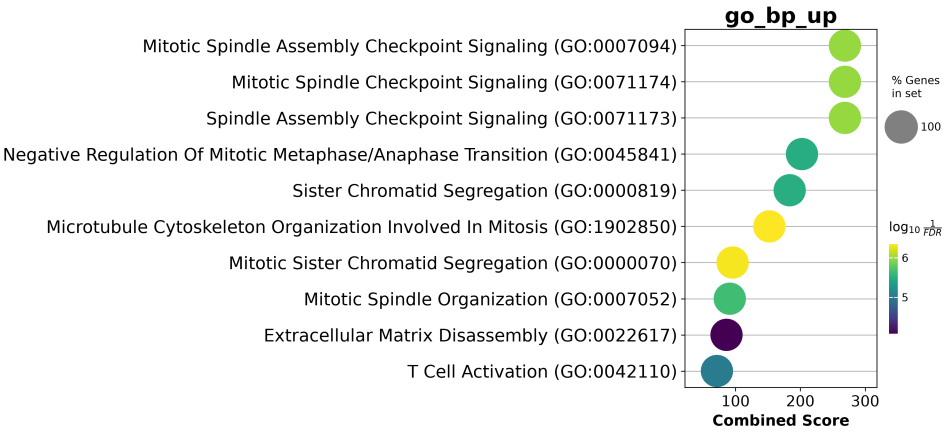



Figura 4: Enriquecimiento GO (Biological Process) en genes Up.

2. Enriquecimiento GO (Biological Process) en genes Down:

Por el contrario, el análisis de procesos biológicos en los genes reprimidos en el tejido mamario tumoral señala términos relacionados con la contracción y el desarrollo muscular, la regulación de la angiogénesis y la modulación de diversas vías de señalización. Esto se debe a la menor representación relativa de elementos del estroma mamario sano y a la alteración de la arquitectura tisular en el tumor (Vargas et al., 2012).

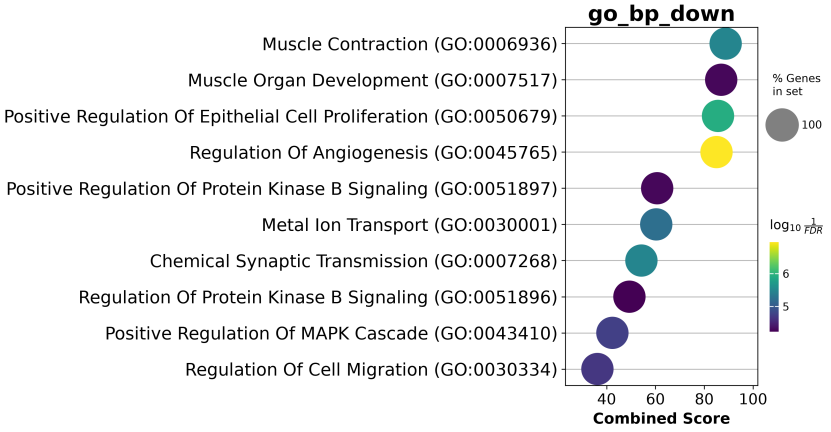



Figura 5: Enriquecimiento GO (Biological Process) en genes Down.

3. Enriquecimiento Reactome en genes Up:

Las vías moleculares de Reactome enriquecidas para el conjunto de genes sobreexpresados en el tumor están vinculadas de nuevo con puntos de control de la mitosis, formación del huso mitótico y separación de cromátidas hermanas. Asimismo, destacan vías de señalización inmunitaria (como interferón alpha/beta), lo que refleja las interacciones que se desarrollan entre las células tumorales y las células inmunitarias y estromales del microambiente (Kim et al., 2021; Vargas et al., 2012).

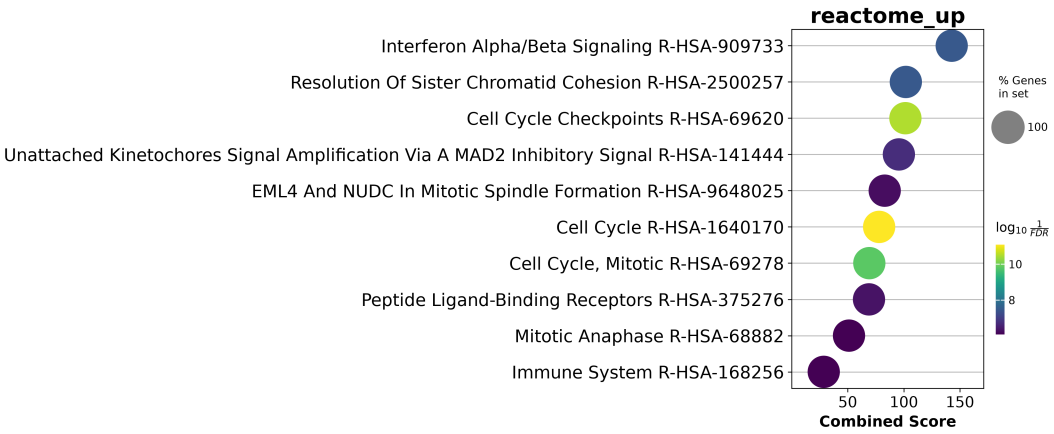



Figura 6: Enriquecimiento Reactome en genes Up.

4. Enriquecimiento Reactome en genes Down:

Las rutas moleculares de Reactome enriquecidas para el conjunto de genes reprimidos en el tumor evidencia vías de transducción de señales mediadas por receptores acoplados a proteínas G (GPCR), diversos procesos metabólicos y contracción muscular. Esto supone una alteración de la señalización metabólica y endocrina que explica la pérdida de funciones especializadas y diferenciación del tejido tumoral mamario.

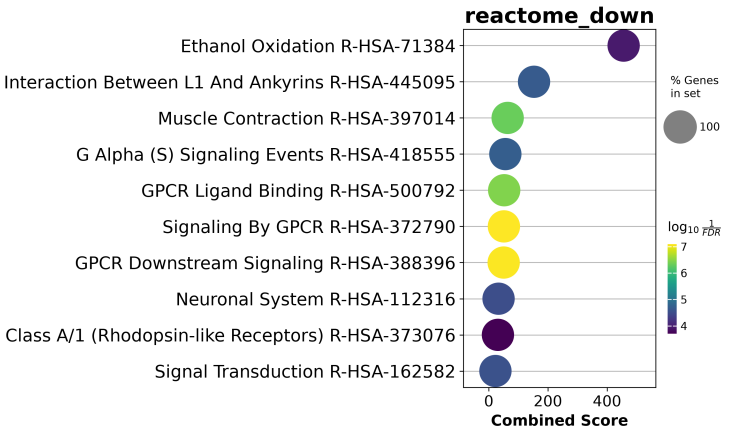



Figura 7: Enriquecimiento Reactome en genes Down.

Comparación: ecosistema Python vs R

Al contrastar los resultados obtenidos en el presente proyecto con el pipeline de Python (PyDESeq2 y GSEApy) con los resultados indicados en el proyecto desarrollado con R, se observa una gran consistencia en la interpretación biológica.

- Coincidencia de los genes destacados: los top 10 de genes sobreexpresados y reprimidos coinciden para ambos entornos, presentando únicamente ciertas variaciones mínimas en los valores de los p-valores ajustados (padj), lo cual se debe a diferencias entre los algoritmos de normalización, el filtrado de genes y el cálculo del p-valor y de su ajuste.

- Interpretación de las figuras: las figuras obtenidas mediante ambas herramientas cuentan la misma historia biológica. La firma up refleja una alta actividad proliferativa y del ciclo celular, mientras que la firma down muestra una reducción en las rutas metabólicas y en la diferenciación en el tejido tumoral.
- ¿Por qué cambian algunos términos del enriquecimiento?: las variaciones en los términos indicados tras el enriquecimiento funcional se deben a varios factores.
  - Biblioteca de genes: mientras que Python consulta de manera directa las bases de datos actualizadas de Enrichr, R accede a repositorios cerrados de Bioconductor.
  - Versión: las bases de datos de Enrichr se actualizan de forma dinámica, lo que difiere del carácter estático de los paquetes de anotación instalados en el entorno de R al desarrollar el proyecto.
  - Universo de fondo (background): aunque para ambos casos se define el universo de fondo con los genes evaluados tras los filtros de calidad, pueden existir diferencias sutiles en los resultados de dicho proceso de filtración, modificando los genes de referencia y alterando los resultados del test estadístico de enriquecimiento funcional.

Referencias bibliográficas

Kim, Hyung Suk et al. (2021). «High MMP-11 expression associated with low CD8+ T cells decreases the survival rate in patients with breast cancer.» En: PloS one 16.5, e0252052. DOI: 10.1371/journal.pone.0252052. URL:https://pubmed.ncbi.nlm.nih.gov/34038440/.

Network, Cancer Genome Atlas (2012). «Comprehensive molecular portraits of human breast tumours.» En: Nature490.7418, págs. 61-70. DOI: 10.1038/nature11412. URL: https://pubmed.ncbi.nlm.nih.gov/23000897/.

Vargas, Ana Cristina et al. (2012). «Gene expression profiling of tumour epithelial and stromal compartments during breast cancer progression.» En: Breast cancer research and treatment 135.1, págs. 153-65. DOI: 10.1007/s10549-012-2123-4. URL: https://pubmed.ncbi.nlm.nih.gov/22718308/.

Zhuang, Ying et al. (2021). «MMP11 promotes the proliferation and progression of breast cancer through stabilizing Smad2 protein.» En: Oncology reports 45.4. DOI: 10.3892/or.2021.7967. URL:https://pubmed.ncbi.nlm.nih.gov/33649832/.

Muzellec, Boris et al. (2023). PyDESeq2: A Python implementation of DESeq2 for bulk RNA-seq analysis (Librería de análisis de expresión diferencial).

Fang, Zhuoxin et al. (2023). GSEAPY: Gene Set Enrichment Analysis in Python (Librería de enriquecimiento funcional frente a Enrichr).

Harris, Charles R. et al. (2020). «Array programming with NumPy.» En: Nature 585.7825, págs. 357-362 (Manipulación numérica y matrices).

McKinney, Wes (2010). «Data structures for statistical computing in Python.» En: Proceedings of the 9th Python in Science Conference, págs. 56-61 (Manipulación de tablas y DataFrames con Pandas).

Hunter, John D. (2007). «Matplotlib: A 2D graphics environment.» En: Computing in Science & Engineering 9.3, págs.90-95 (Generación de gráficos científicos, MA plots y Volcano plots).